INFORMATIQUE

Laboratoires de bases de données

Laboratoire n°4

Groupements, imbrications et ensembles

par Danièle BAYERS et Louis SWINNEN
Révision 2024 : Vincent Reip

Janvier 2024

1. Objectif

L'objectif de ce laboratoire est de décrire les opérations de groupement, les requêtes imbriquées (également appelée sous-select ou sous-requêtes) et les requêtes ensemblistes (au moyen des opérateurs ensemblistes `UNION`, `INTERSECT`, `MINUS`).

Nous terminerons en abordant les requêtes particulières avec `case`, `exists`, `any` et `all`.

2. La base de données

Dans les exemples, nous supposerons que nous disposons de la base de données suivante :

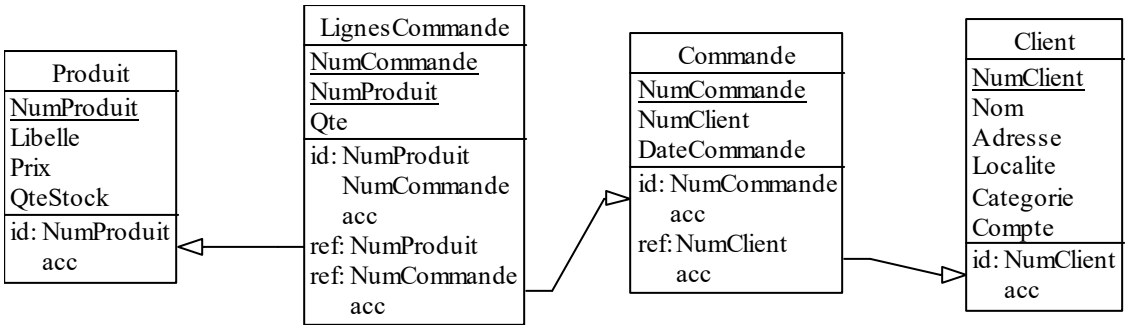

3. Requêtes sur les groupes

Grâce aux requêtes sur les groupes, il est possible d'obtenir des résultats groupés qui peuvent s'avérer intéressants. Ces requêtes sur les groupes utilisent des *fonctions de groupe* (appelées aussi fonctions d'agrégat).

La requête SQL pourra donc spécifier un ou plusieurs critères de groupement des tuples et appliquer, à chacun des groupements, une ou plusieurs fonctions de groupe. Par exemple, nous pourrions demander au SGBD de nous fournir le nombre de client par localité avec la requête suivante :

```
SELECT localite, COUNT(*) AS NB_CLIENTS
FROM client
GROUP BY localite
```

Le résultat obtenu aurait alors la forme suivante :

LOCALITE	NB_CLIENTS
Liège	15
Namur	24
Tournai	8
Verviers	17

On peut considérer que le traitement de la clause GROUP BY a amené le SGBD à créer 4 groupements de tuples (on considère dans l'exemple qu'il y a 4 valeurs distinctes de localité dans la table `client`). L'utilisation de la fonction d'agrégation COUNT a ensuite amené le SGBD à simplement compter le nombre de tuples dans chacun des groupements.

3.1 Les fonctions d'agrégation SQL

Le langage SQL prévoit les fonctions d'agrégation suivantes applicables à un attribut :

- `AVG` – calcule la moyenne
- `MAX` – Retourne la plus grande valeur
- `MIN` – Retourne la plus petite valeur
- `COUNT` – Compte le nombre de résultat
- `SUM` – Effectue une somme

Ces fonctions d'agrégation prennent en argument le nom de l'attribut. Elles peuvent également intégrer le mot clé `DISTINCT` qui supprime les valeurs identiques.

Ces fonctions d'agrégation peuvent être utilisées avec ou sans clause de groupement (GROUP BY). S'il n'y a pas de clause de groupement, la fonction s'applique à l'ensemble des tuples de la requête.

Exemples :

```
SELECT AVG(prix)
FROM produit
```

Obtenir le prix moyen des produits – cette requête renvoie une seule valeur peu importe le nombre de tuples dans la table `produit`*.*

Pour clarifier l'utilisation de `COUNT`, voici quelques exemples en guise d'illustration :

```
SELECT *
FROM client
```

Retourne tous les enregistrements de la table client (n lignes)

```
SELECT COUNT(*)
FROM client
```

Retourne le nombre d'enregistrements présents dans la table client (i.e. le nombre de lignes du résultat précédent).

```
SELECT COUNT(categorie)
FROM client
```

Retourne le nombre d'enregistrements présents dans la table client pour lesquels la catégorie n'est pas nulle.

```
SELECT COUNT(DISTINCT categorie)
FROM client
```

Retourne le nombre de valeurs différentes présents dans l'attribut catégorie.

3.2 Les clauses GROUP BY et HAVING

La clause GROUP BY permet de regrouper les résultats autour de valeurs d'attribut déterminées. Cette clause est utilisée en combinaison avec des fonctions de groupe.

Forme :

```
SELECT attr1, …, attri, fct_groupe1(attrj), …, fct_groupen(attrp)
FROM table1
[JOIN tablen ON conditionx]
[WHERE conditiony]
GROUP BY attr1, …, attri
[HAVING conditionz]
```

Dans la forme présentée ci-dessus, il faut remarquer ceci :

- L'utilisation conjointe d'attributs et de fonctions de groupe dans le `SELECT` **impose** l'utilisation d'une clause `GROUP BY`
- Le `GROUP BY` doit souvent reprendre les attributs n'intégrant pas les fonctions de groupe
- La clause `WHERE` ne peut reprendre dans sa condition que des attributs
- La clause `HAVING` permet de filtrer les résultats d'une fonction de groupe
- Dans `fct_groupe`, on retrouve les fonctions de groupe montrées plus haut : `SUM`, `MAX`, `MIN`, `AVG` et `COUNT`.

Exemple :

```
SELECT cli.localite, SUM(p.prix * lc.qte) CA
FROM client cli
JOIN commande c ON cli.numClient = c.numClient
JOIN lignesCommande lc ON lc.numCommande = c.numCommande
JOIN produit p ON lc.numProduit = p.numProduit
GROUP BY cli.localite
```

Cette requête retourne comme résultat le chiffre d'affaires par localité. Le résultat montrera les localités différentes et le chiffre d'affaires calculé.

La clause `HAVING` peut être définie comme suit : « *il s'agit d'une clause `WHERE` sur un groupe définit par `GROUP BY` »* (définition extraite de [1]). Tout comme la clause `WHERE`, la clause `HAVING` limite le résultat aux seuls enregistrements vérifiant la condition énoncée.

Exemple :

```
SELECT cli.categorie, SUM(p.prix * lc.qte) CA
FROM client cli
JOIN commande c ON cli.numClient = c.numClient
JOIN lignesCommande lc ON lc.numCommande = c.numCommande
JOIN produit p ON lc.numProduit = p.numProduit
WHERE cli.localite IN ('Liege', 'Bruxelles')
GROUP BY cli.categorie
HAVING SUM(p.prix * lc.qte) > 500
```

Dans cet exemple, on calcule le chiffre d'affaires par catégorie de client, uniquement pour les clients de Liège et de Bruxelles. On filtre le résultat pour garder uniquement les catégories dont le chiffre d'affaires est supérieur à 500.

On remarque dans cet exemple l'utilisation différente de `WHERE` et `HAVING`. `WHERE` est utilisé pour filtrer les catégories, attribut de la table client tandis que `HAVING` est utilisé pour filtrer le résultat d'une fonction de groupe, ici `SUM`. Même si c'est toléré (et optimisé) par le SGBD, ce n'est pas une bonne pratique d'utiliser la clause `HAVING` pour spécifier une condition sur un attribut.

4. Les requêtes imbriquées

Grâce à l'imbrication des requêtes, il est possible d'obtenir des résultats relativement complexes par la combinaison de plusieurs requêtes simples. De telles requêtes sont très souvent utilisées car elles permettent d'obtenir des résultats plus intéressants.

Le schéma des requêtes imbriquées est souvent le suivant :

```
SELECT attr1, …, attrn
FROM table1
[JOIN table2 ON condition]
WHERE attrx = ( SELECT attry
                FROM table3
                [JOIN table4 ON condition]
                WHERE condition )
```

Il existe plusieurs formes de requêtes imbriquées. La forme présentée ici comprend un opérateur de comparaison (=). Nous pourrions également trouver un opérateur d'appartenance (`IN` ou `NOT IN`). Nous allons examiner ces deux formes ci-après.

Exemples :

```
SELECT c.NumCommade, c.DateCommande
FROM Commande c
WHERE c.Numclient = (SELECT cl.NumClient
                     FROM Client cl
                     WHERE Compte = '001-3215487-89')
```

La requête ci-dessus permet de retrouver les numéros et dates de commande d'un client dont on connait le numéro de compte (mais pas le numéro de client). On considère que la sous-requête retournera une seule valeur car le numéro de compte est une clé candidate de la relation Client.

Il est également possible d'imbriquer des requêtes déjà imbriquées (voir *exemple 1* ci-dessous). Il arrive également de créer une requête ayant deux conditions imbriquées séparées par des opérateurs logiques comme `OR` ou `AND` (voir *exemple 2* ci-après). **Dans l'illustration ci-dessous, ces deux formes ne sont pas équivalentes**.

Exemple 1 :

```
SELECT attr1, …, attrn
FROM table1
WHERE attrx = (SELECT attry
                 FROM table2
                 WHERE attrz < (SELECT attrp
                                  FROM table3
                                  WHERE condition)
              )
```

Exemple 2 :

```
SELECT attr1, …, attrn
FROM table1
WHERE attrx = (SELECT attry
                 FROM table2
                 WHERE condition1 )
OR attrz < ( SELECT attrp
```

```
                FROM table3
                WHERE condition2)
```

Les requêtes imbriquées peuvent aussi être utilisées au sein de requêtes de type INSERT, UPDATE ou DELETE. Par exemple, on peut utiliser une sous-requête pour « générer » une nouvelle valeur de clé primaire :

```
INSERT INTO Produit (NumProduit, Libelle, Prix, QteStock)
VALUES ( (SELECT MAX(NumProduit)+1 FROM Produit), 'Lecteur DVD Sony
RX-14', 114, 10)
```

On peut aussi utiliser une sous-requête pour trouver la valeur à affecter à une clé étrangère lorsqu'on ne connaît pas l'identifiant du tuple à référencer :

```
INSERT INTO LignesCommande (NumCommande, NumProduit, Qte)
VALUES (43, (SELECT NumProduit FROM Produit WHERE Libelle = 'Lecteur
DVD Sony RX-14'), 1)
```

Attention, il faut évidemment s'assurer que la sous-requête renvoie une et une seule valeur ; en d'autres termes, on considère dans l'exemple ci-dessous que l'attribut `Libelle` est une clé candidate.

4.1 Utilisation d'un opérateur de comparaison

Pour utiliser une requête imbriquée impliquant un opérateur de comparaison (=, <, >, <=, >=, <>), il est nécessaire que la requête interne **ne retourne qu'une seule colonne et une seule ligne** (une seule valeur donc), qui doit pouvoir être comparée à l'attribut mentionné dans le `WHERE` de la 1ère requête.

C'est le cas dans le format présenté ci-dessous puisque la clause `SELECT` ne précise qu'une seule colonne et qu'on a émis l'hypothèse que le libellé d'un produit était une clé candidate.

Exemples :

```
SELECT Nom, adresse
FROM client cli
JOIN Commande c on cli.numClient = c.numClient
JOIN ligneCommande lc ON c.numCommande = lc.numCommande
WHERE lc.numProduit = (SELECT p.numProduit
                       FROM produit
                       WHERE libelle = 'DVD WALL-E')
```

Obtenir le nom et l'adresse des clients ayant commandé le produit portant le libelle DVD WALL-E.

```
SELECT numProduit, libelle
FROM produit
WHERE prix > (  SELECT AVG(prix)
                FROM produit )
```

Obtenir les produits dont le prix est supérieur au prix moyen.

Afin d'assurer que le résultat de la requête interne ne contient qu'une seule ligne, il est donc très fréquent que le `WHERE` porte sur une valeur précise d'une clé candidate.

4.2 Utilisation d'un opérateur d'appartenance

La forme précédente est souvent trop limitée, c'est pourquoi on trouve régulièrement, dans les requêtes imbriquées, l'opérateur d'appartenance.

La forme de la requête change peu :

```
SELECT attr1, …, attrn
FROM table1
WHERE attrx [NOT] IN (SELECT attry
                      FROM table2
                      WHERE condition )
```

On remarque la présence des opérateurs `IN` ou `NOT IN` de **comparaison à une liste de données**.

Cette forme impose à la requête imbriquée de retourner **une seule colonne**. Mais la valeur de la colonne peut maintenant prendre en ensemble de valeurs. Ainsi le SGBD sélectionnera les enregistrements dont l'attribut prend une valeur parmi l'ensemble donné.

Exemple :

```
SELECT Nom, adresse
FROM client cli
JOIN Commande c on cli.numClient = c.numClient
JOIN ligneCommande lc ON c.numCommande = lc.numCommande
WHERE lc.numProduit IN (SELECT p.numProduit
                            FROM produit
                            WHERE libelle LIKE '%digital%')
```

Sélectionne le nom et l'adresse des clients ayant commandé un produit dont le libellé contient le mot « digital ».

5. Les opérateurs ensemblistes

SQL-2 définit les opérateurs ensemblistes suivant : *l'union*, *l'intersection* et *la différence.* Ces opérateurs travaillent sur les résultats des requêtes qui peuvent être considérés comme des ensembles.

Ainsi, grâce à l'opérateur *union* il est possible de réunir, dans le même résultat, les enregistrements issus de 2 requêtes. L'*intersection* va permettre de garder uniquement les résultats communs à deux requêtes. Finalement *la différence* permet de garder uniquement les résultats de la première requête qui n'apparaissent pas dans la seconde requête.

Il faut noter que les SGBD supportent diversement les opérateurs ensemblistes.

5.1 L'union

Format :

```
SELECT attr1, …, attrn
FROM table1 t1
[JOIN table2 t2 ON t1.attrx = t2.attry]
WHERE …
[ORDER BY …]

UNION [ALL]

SELECT attr1, …, attrn
FROM table3 t3
[JOIN table4 t4 ON t3.attrv = t4.attrw]
WHERE …
[ORDER BY …]
```

Le résultat contiendra les résultats des deux requêtes *sans les éléments dupliqués*. Pour faire apparaître tous les résultats, on utilisera UNION ALL. Pour obtenir un résultat correct, il est nécessaire que les deux requêtes retournent un nombre de colonne identique et des valeurs compatibles (si le 1ier attribut dans le résultat de la 1ère requête est un entier, il est nécessaire qu'il en soit de même dans la seconde requête).

Cette commande est disponible sous *Oracle* et *SQL Server*.

Exemple :

```
SELECT numCommande, numClient, dateCommande
FROM commande
WHERE numClient = 'C001'
UNION
SELECT numCommande, numClient, dateCommande
FROM commande
WHERE numClient = 'C003'
```

Liste les commandes des clients C001 et C003.

5.2 L'intersection

Format :

```
 SELECT attr1, …, attrn
FROM table1 t1
[JOIN table2 t2 ON t1.attrx = t2.attry]
WHERE …
[ORDER BY …]

INTERSECT

SELECT attr1, …, attrn
FROM table3 t3
[JOIN table4 t4 ON t3.attrv = t4.attrw]
WHERE …
[ORDER BY …]
```

Le résultat contiendra uniquement les enregistrements communs aux deux requêtes. Le nombre de colonne ainsi que leur type doit être compatible afin que le SGBD puisse opérer l'intersection entre les deux résultats.

Cette commande est disponible sous *Oracle* et *SQL Server (>= 2005).*

Exemple :

```
SELECT numclient
FROM commande
WHERE EXTRACT(YEAR FROM DateCommande) = 1995
INTERSECT
SELECT numclient
FROM commande
WHERE EXTRACT(MONTH FROM DateCommande) = 10
```

Liste les clients ayant commandés en 1995 et durant le mois d'octobre. Attention, dans cette formulation, un client ayant commandé en octobre 1994 et en juin 1995 apparaîtrait dans le résultat.

5.3 La différence

Format :

```
SELECT attr1, …, attrn
FROM table1 t1
[JOIN table2 t2 ON t1.attrx = t2.attry]
WHERE …
[ORDER BY …]

EXCEPT

SELECT attr1, …, attrn
FROM table3 t3
[JOIN table4 t4 ON t3.attrv = t4.attrw]
WHERE …
[ORDER BY …]
```

Le résultat contiendra les enregistrements de la première requête qui ne sont pas présents dans la seconde.

Cette commande est disponible sous *Oracle* (et s'appelle `MINUS`) et *SQL Server (>= 2005).*

Exemple :

```
SELECT numProduit
FROM produit
WHERE LOWER(libelle) LIKE '%informatique%'
EXCEPT
SELECT numProduit
FROM produit
WHERE LOWER(libelle) LIKE '%numerique%'
```

Sélectionne les produits dont le nom contient informatique mais pas numerique.

6. Les requêtes plus complexes

Parmi les requêtes plus complexes, nous allons étudier les expressions CASE et EXISTS.

6.1 CASE

La commande CASE permet de gérer des conditions. Le CASE s'insère très souvent dans le SELECT (à l'intérieur de la liste des résultats) ou dans un UPDATE.

Format :

```
SELECT attr1, …, attrn,
  CASE
  WHEN attri = vali THEN valq
  WHEN attri = valj THEN valr
  …
  [ELSE NULL]
  END
FROM table1 t1
[JOIN …]
WHERE …
[ORDER BY …]
```

Dans le résultat, à la suite de l'attribut $attr_n$, le SGBD ajoutera une des valeurs val_q, val_r, … suivant la condition qui sera vérifiée dans le `CASE` ou `NULL` si aucune condition ne l'est.

```
UPDATE table1
SET attr1 = CASE
                WHEN attri = vali THEN valq
                WHEN attrj = valj THEN valr
                …
                [ELSE NULL]
            END
```

Ici, l'attr1 prendra une valeur qui dépendra de la condition qui sera vérifiée dans le `CASE` ou `NULL` si aucune condition ne l'est.

Exemples :

```
SELECT nom, adresse,
  CASE
    WHEN categorie = 'C1' THEN 'Particulier'
    WHEN categorie = 'C2' THEN 'Administration'
    WHEN categorie = 'C3' THEN 'PME'
    WHEN categorie = 'C4' THEN 'Entreprise'
    ELSE 'Inconnu'
    END
FROM Client
```

Dans cet exemple, on affiche le nom, le prénom et la catégorie du client.

```
UPDATE Produit
SET prix = CASE
                WHEN QteStock < 10  THEN prix * 2
                WHEN QteStock < 100 THEN prix * 1.5
                WHEN QteStock >=100 THEN prix
            END
WHERE libelle LIKE '%digital%'
```

Dans cet exemple, on ajuste le prix des produits dont le libellé contient le mot 'digital' en fonction de la quantité en stock..

6.2 Exists

Format :

```
SELECT attr1, …, attrn
FROM table1 t1
[JOIN table2 t2 ON t1.attrx = t2.attry]
WHERE EXISTS (SELECT *
              FROM table3 t3
              …)
[ORDER BY …]
```

La clause `EXISTS` est un peu particulière et déroutante. En fait, une expression `WHERE EXISTS` est évaluée à VRAI si la requête qui suit retourne un résultat non-vide quel qu'il soit (au moins un tuple dois donc être retourné). Dans notre format, la requête `WHERE EXISTS` sera vraie si la requête concernant la table *t3* retourne au moins une tuple (une ligne).

La clause inverse est `WHERE NOT EXISTS`. Elle est évaluée à VRAI si la requête qui suit ne retourne aucun résultat (aucune ligne).

Les requêtes de type `[NOT] EXISTS` utilisent la forme `SELECT *` puisque la seule chose importante est de déterminer si un résultat est retourné (peu importe les colonnes impliquées).

Attention ! L'évaluation de EXISTS n'est pas toujours aisée en présence des valeurs NULL. Ainsi, nous avons vu précédemment qu'une expression dont un opérande est évalué à NULL retourne elle aussi un résultat vide. Dans l'évaluation d'un NOT EXISTS, il convient de prendre en compte cette possibilité. Si la requête interne ne retourne pas de résultat à cause d'une valeur NULL, la clause NOT EXISTS sera évalué à vraie (car il n'y a pas de résultat).

Exemple :

```
SELECT *
FROM client cl
WHERE NOT EXISTS ( SELECT *
                   FROM Commande co
                   WHERE cl.numClient = co.numClient)
```

Liste les clients n'ayant pas commandé.

Il faut noter que la requête interne liée à une clause [NOT] EXISTS intégrera généralement dans sa clause WHERE une condition faisant intervenir un attribut d'une table interrogée dans la requête principale.

6.3 ALL

Format :

```
SELECT attr1, …, attrn
FROM table1 t1
[JOIN …]
WHERE attrx [>|<|=|>=|<=] ALL (  SELECT attry
                                 FROM table2 t2
                                 …)
[ORDER BY …]
```

L'expression WHERE sera évaluée à vraie si la comparaison entre $attr_x$ et chaque résultat retourné par la requête interne (sur la table *t2*) est évaluée à vraie. Cette expression sera également vraie si la requête interne retourne un résultat vide. En conséquence, si la

comparaison entre $attr_x$ et une valeur du résultat n'est pas vérifiée, l'expression sera évaluée à faux.

Ainsi, comme le précise [2], nous pouvons noter que `<> ALL` est équivalent à `NOT IN`.

Exemple :

```
SELECT lc.numCommande
FROM ligneCommande lc
WHERE lc.qte > ALL (SELECT lc2.qte
                    FROM ligneCommande lc2
                    WHERE lc2.numcommande <> lc.numcommande)
```

Sélectionne la commande dont la quantité commandée est supérieure à toutes celles des autres commandes (cette requête aurait pu être écrite en utilisant `MAX`).

6.4 ANY

Format :

```
SELECT attr1, …, attrn
FROM table1 t1
[JOIN …]
WHERE attrx [>|<|=|>=|<=] ANY (  SELECT attry
                                 FROM table2 t2
                                 …)
```

L'expression WHERE sera évaluée à vraie si la comparaison entre $attr_x$ et l'un des résultats retournés par la requête interne (sur la table *t2*) est évaluée à vraie. En conséquence, si la comparaison entre $attr_x$ et chaque résultat n'est pas vérifiée, l'expression sera évaluée à faux.

Il faut également noter que `= ANY` est équivalent à l'opérateur `IN` (tiré de [2]).

Bibliographie

[1] C. MAREE et G. LEDANT, *SQL-2 : Initiation, Programmation*, 2ème édition, Armand Colin, 1994, Paris

[2] P. DELMAL, *SQL2 – SQL3 : application à Oracle*, 3ème édition, De Boeck Université, 2001, Bruxelles

[3] Microsoft, MSDN Microsoft Developper Network, http://msdn.microsoft.com, consulté en février 2009, Microsoft Corp.

[4] Diana Lorentz, et al., Oracle Database SQL Reference, 10g Release 2 (10.2), published by Oracle and available at http://www.oracle.com/pls/db102/homepage, 2005

[5] JL. HAINAUT, *Bases de données: concepts, utilisation et développement*, Dunod, 2009, Paris.